完整试验记录

TGRS 2019-2023 全流程实验总结

覆盖 E1-E8、补充实验、ACT-Former v2-v8+、DSCF、确认实验、基础设施重构与 hardening 全部阶段

数据版本	EGMS 2019-2023 Ortho U（统一数据源）
主线任务	区域地表形变 nowcasting / 多步预测 / 跨 tile 泛化 / 安全聚合
主分辨率	64×64（主任务）；128×128 与 512×512 仅作 sensitivity/robustness
当前最终主线	Strong-Baseline-Aware Expert Aggregation：VCEA 为主精度版本，SS-VCEA 为保守部署变体

统一数据声明：本项目全部正式实验均基于 EGMS 2019-2023 Ortho U。原因不是方法偏好，而是数据可得性约束：该版本完成了本地提取、预处理、泄漏审计、split 固化与统一可复现实验链路，故后续所有模型比较均在同一数据口径下进行。

文档用途

- 作为当前 `outputs/tgrs_2019_2023` 目录下全项目实验的汇总档案，统一记录数据口径、切分协议、模型演化、关键结果与最终结论。
- 直接服务论文写作、答辩/审稿应答、结果复核和后续复现实验，不再依赖分散的阶段性报告逐个拼接。

一、项目总览与最终状态

项目主问题：在强 persistence baseline 下，针对 EGMS 区域地表形变栅格序列建立 leakage-safe 的 nowcasting 框架，比较单模型、门控残差、多尺度状态空间、专家选择与专家聚合等多种方法。

实验总体路线：先完成 E1-E8 基线与诊断，再做必须补实验，随后沿 ACT-Former v2 到 v8+ 展开结构改进；当单模型路线收益受限后，转入 COEA/VCEA/SS-VCEA 聚合路线，并在后期补上 external locked validation、resolution sensitivity、infra_v2 可追溯层与 hardening。

当前最强精度主线：Static validation-weighted expert aggregation（VCEA），best static config = StaticVal_inverse_temp4p0_sh0p1_floor0p0，main-six Mean Skill_MSE = 0.1776，gain vs M1 = +0.0993。

当前最稳部署变体：SS-VCEA-COEA_q97p5，main-six Mean Skill_MSE = 0.1648，stress ratio = 0.9917；external locked 上作为 conservative deployment variant 保留。

最强单模型主线：M1 / PG-RQ-ACT（其后在六 tile 与消融中冻结为更简单的 scalar gate 版本 C2），full-six Mean Skill_MSE = 0.0783。

关键研究结论：更复杂的单一神经架构并未稳定击败强基线，而由 persistence、linear-seasonal、M1、C3_opt 组成的专家聚合家族给出了更强的 accuracy-efficiency trade-off；其中 static validation weighting 明显优于多数 online selector/aggregator 方案。

二、实验数据、预处理、训练载入与切分协议

2.1 使用的数据产品

主线实验使用 6 个 EGMS Ortho U 2019-2023 tile；后期 external locked evaluation 额外使用 4 个 external tile。主线 6 个 tile 如下。

Tile	角色	主导 regime	时序帧数	Valid64 比例
E32N34	source_main	mixed	303	0.772
E32N35	nearby_seasonal	seasonal	303	0.786
E39N30	subsidence_1	subsidence	302	0.955
E44N23	subsidence_2	subsidence	302	0.924
E48N24	coseismic_1	coseismic	302	0.183
E58N17	coseismic_2	coseismic	301	0.152

external locked evaluation 使用的 4 个 tile 如下，均来自同一 2019-2023 Ortho U 版本。

External tile	主导 regime	时序帧数	Valid64 比例
E37N42	mixed	301	0.389
E45N51	mixed	112	0.241
E30N35	mixed	302	0.765
E42N21	mixed	302	0.689

2.2 数据处理流程

1. 从 `data/raw` 解包 zip，并读取每个 tile 的 CSV 与 XML；日期列由代码自动检测，原始观测点保留为规则 100 m 网格上的点序列。
2. 将点级位移与描述子聚合为 `64×64` 与 `128×128` 粗网格；确认实验阶段再扩展到 `512×512` sensitivity。主 rasterization 采用 point-to-cell 均值，空单元用最近邻补值，仅用于构造密集张量。
3. 仅用训练窗口拟合辅助描述子：velocity、acceleration、seasonal amplitude、seasonal phase、residual std、trend R^2；time-of-year 通过 `sin/cos(DOY)` 编码。
4. 像元级 regime map 由 full-series coarse descriptor 推断，仅用于 E6/E8 诊断与后期 regime 分析，不进入正式模型输入。
5. 将处理结果写入 `data/processed/tgrs_2019_2023/<tile>`，同时固化 `split.json`、`data_manifest.csv`、`normalization_policy.md` 与 `leakage_check_report.md`。

2.3 训练 / 验证 / 测试切分与样本构造

- 统一 chronological split：70% train / 10% val / 20% test。E32N34/E32N35 为 303 帧时，train 截止第 212 帧、val 截止第 242 帧；302 帧 tile 为 211/241；301 帧 tile 为 210/240。
- 统一输入长度 `input_len=16`，统一预测步长 `t+1 / t+3 / t+5 / t+10`。
- 窗口按目标时刻归属 split：train 从 `input_len-1` 到 train 结束前，val 从 train_end 起，test 从 val_end 起；输入窗口允许跨 split 边界，但不允许访问目标时刻之后的未来帧。
- Dataset 输出统一包含：输入张量 `x`、多步目标 `y`、valid mask、regime map、最后一帧原始位移 `last_disp_mm`。train loader 随机打乱，val/test loader 不打乱。

2.4 归一化与跨站点加载策略

- In-tile：位移均值/标准差与静态特征统计量只在同 tile 的训练窗口上计算。
- Cross-site / zero-shot / transfer：位移与静态特征归一化统计来自 source tile；但目标 tile 的辅助特征仍按目标历史序列本身计算。

- Local calibration：E5 中限制的是监督微调窗口数量，而不是目标 pre-test history 的可见长度，因此目标辅助特征与归一化仍基于目标 pre-test history 计算。
- 评估统一使用 valid-mask 加权指标；最近邻补值不计入 valid-pixel 指标分母。

2.5 统一评价指标

- 基础误差：RMSE、MAE、R^2、Pearson、SSIM。
- 阈值精度：Acc@1mm、Acc@0.5mm，部分确认实验还记录 Acc@0.2mm。
- 相对强基线指标：Skill_MSE = 1 - MSE_model / MSE_persistence，Skill_RMSE。
- 安全与部署指标：stress ratio、better tiles、gate 权重、fallback rate、external locked gain。
- 物理诊断指标：velocity-sign consistency、post-event recovery ratio、jump rate、regime-wise metrics。

三、 E1-E8 主实验与必须补实验

E0 预处理与数据审计

阶段目标：建立统一数据管线，替换旧稿中的 2018-2022 口径，确保 2019-2023 Ortho U 六 tile 能稳定进入后续所有实验。

参考模型/已有方法：不是模型对比阶段，而是全项目的数据与 split 基准。

主要结果：完成六个 tile 的解包、64×64/128×128 栅格化、70/10/20 split、训练窗描述子重拟合、regime map 生成与 leakage-safe 审计。

阶段进展：为 E1-E8 以及后续所有模型家族提供统一输入。

不足与注意事项：出于当轮可执行性，主栅格化采用 coarse regional aggregation，而不是更重的散点插值流程。

E1 辅助特征消融（A0-A6）

阶段目标：验证 velocity / acceleration / seasonal/time 编码是否能提升 ACT-Former。

参考模型/已有方法：参考模型是无辅助特征 A0；后续重点比较 A0、A4、A5、A6。

主要结果：A6 只在部分 tile 最优：E44N23、E48N24 表现最好；E32N34、E32N35、E58N17 反而是 A0 更优；E39N30 则 A4 最优。

阶段进展：直接否定了“辅助特征 universal improvement”的简单叙事。

不足与注意事项：后续 A3 regime-wise 分解进一步证明，A6 只对 subsidence/accelerating 有轻微帮助，在 seasonal/coseismic 上会退化。

E2 架构消融（B0/B2/B4/B5/B7/B8）

阶段目标：比较 CNN-LSTM/STGCN/ACT 变体，验证 query token、residual prediction 和损失设计的价值。

参考模型/已有方法：已有模型包含 CNN-LSTM、STGCN，以及无 query / 无 residual 的 ACT 变体。

主要结果：B7、B8、B4 明显优于 B0/B2；B5 no-residual 在 E32N34 上直接崩塌，RMSE 约 2.5 mm 量级。

阶段进展：确立 residual prediction 是核心组件，query token 有稳定正贡献。

不足与注意事项：在轻量预算下，B7 SmoothL1-only 略优于 B8，说明复合损失并非稳定的主贡献点。

E3 多步长 nowcasting

阶段目标：评估单模型同时输出 `t+1/t+3/t+5/t+10` 时的退化曲线。

参考模型/已有方法：原始主线先看 ACT-Former 自身，随后在 A2 中补 persistence 与 linear-seasonal。

主要结果：三 tile 都随 horizon 增大而退化；E48N24 退化最明显。

阶段进展：说明多步长难度与 abrupt regime 强相关。

不足与注意事项：补 baseline 后发现 ACT 优势明显依赖 tile：E32N34 长步更强，E39N30 短期 persistence 更强且长期 linear-seasonal 更强，E48N24 全程 persistence 最强。

E4 零样本跨站点迁移

阶段目标：评估 source-only 到 target 的跨站点迁移可行性。

参考模型/已有方法：以 E32N34 为 source，对其余 5 个 target 做 source-only 迁移；再补 leave-one-tile-out exploratory proxy。

主要结果：source-only 到 E32N35/E39N30/E44N23 仍有可用结果，到 E48N24/E58N17 更难。

阶段进展：说明 smooth/subsidence tile 具备一定 transferability，co-seismic 明显更难。

不足与注意事项：当前 LOTO 使用单源 proxy，不是严格多源联合训练；这一点在报告中已显式标注。

E5 有限本地校准

阶段目标：评估目标域只给少量本地样本时，zero-shot、few-shot calibration、scratch 与 full site-specific 的差异。

参考模型/已有方法：对照包括 zero-shot、5/10/20% calibration、同量级 scratch 与 full site-specific 上界。

主要结果：有限校准并非所有 target 都稳定增益，尤其 co-seismic tile 仍然困难；E58N17 对 calibration 更敏感，E39N30 则收益有限。

阶段进展：表明目标域少量监督有价值，但收益是场景依赖的。

不足与注意事项：当前实现限制的是监督微调窗口数量，而不是目标历史长度不可见，这一点必须在论文里说清。

E6 Leave-one-tile-out / regime 诊断

阶段目标：从像元级 regime 角度理解跨 tile 误差模式。

参考模型/已有方法：复用 E4 的 proxy 结果，按 stable/seasonal/subsidence/accelerating/coseismic/mixed 重算指标。

主要结果：stable 通常最好；seasonal、accelerating、coseismic 一般更难；E58N17 的 coseismic RMSE 最高。

阶段进展：为后续 gate、risk、aggregation 的 regime 分析提供了经验依据。

不足与注意事项：由于复用的是 E4 proxy，E6 更适合做诊断，不适合作为严苛的最终 transfer 证据。

E7 分辨率与 hotspot 敏感性

阶段目标：比较 64×64 与 128×128，并检验局部热点裁剪是否带来额外收益。

参考模型/已有方法：以 ACT-Former 和 persistence 为主，后续 A5 又补了 compute table。

主要结果：E32N34 上 64×64 的 RMSE 明显优于 128×128；128×128 的 SSIM 略高，但幅值恢复更差。

阶段进展：早期就提示“更高分辨率不等于更强整体预测”。

不足与注意事项：hotspot 部分采用 E39N30 自动裁窗近似，属于探索性补充，不是全分辨率重训结论。

E8 物理一致性与可解释性诊断

阶段目标：检查速度符号一致性、非物理跳变和震后恢复行为。

参考模型/已有方法：主对比为 A0/A6，并在 A4 中对指标做更合理的重定义。

主要结果：原始 velocity-sign consistency 仅约 0.4023；E48N24 与 E58N17 的 post-event realignment time 很长。

阶段进展：说明模型即便有可接受像素误差，也仍存在物理一致性不足的问题。

不足与注意事项：A4 重定义后，moving-pixel consistency 更合理，但对 E48/E58 由于 pre-event 测试段不足，需要保留 post-only fallback 说明。

A1-A5 必补实验

A1 / E2 三种子复验：B5 no-residual 仍然灾难性退化；B4 no-query 稳定差于 B8；B7 在轻量预算下略优于 B8。结论是 residual prediction 为核心贡献，query token 有贡献，但复合损失不能写成绝对主贡献。

A2 / E3 baseline 补齐：为 E32N34/E39N30/E48N24 补 persistence 与 linear-seasonal。结果显示 ACT 的 horizon 优势不是 universal：E32N34 长步优于 persistence，E39N30 长步 linear-seasonal 最强，E48N24 全程 persistence 最强。

A3 / E1 regime-wise 分解：A6 仅在 subsidence 与 accelerating 上有轻微优势，在 seasonal 与尤其 coseismic 上退化，从机制上解释了 E1 tile-level 结果为何不一致。

A4 / E8 指标重定义：将 velocity-sign consistency 限定到 `|velocity|>=1 mm/yr` 且 `trend $R^2$>=0.6` 的 moving pixels，并用 recovery ratio 替代直接的 step 数量指标，提高了 E8 诊断可解释性。

A5 / E7 compute table：补齐 64×64 与 128×128 的参数量、显存、训练/推理时间，支持“128×128 SSIM 略高但 RMSE 更差”的 accuracy-compute trade-off 解释。

四、ACT-Former v2-v4：单模型路线的系统探索

V2：Persistence-Gated Residual ACT（M1）

阶段目标：在三 tile 搜索集上构造比原始 ACT 更稳的 baseline-aware residual 模型。

参考模型/已有方法：参考模型为 M0/B7 及原 ACT 变体；基线是 persistence。

主要结果：M1 quick Mean Skill_MSE = 0.0473，3-seed = 0.0446 ± 0.0059，E48N24 最差 RMSE/persistence = 1.0018，顺利过三 tile GO。

阶段进展：第一次把单模型路线从“能工作”推进到“在三 tile 上稳定正 skill”。

不足与止损原因：仍然只是三 tile search 主线，必须进一步做 full-six 和结构消融。

V2 full-six + gate 消融

阶段目标：把 M1 扩展到六 tile、四个 horizon、三 seeds，并确认 gate 结构贡献。

参考模型/已有方法：对照 persistence、linear-seasonal、M0/B7，以及 C1-C8 结构消融。

主要结果：patch gate 版本 full-six mean Skill_MSE = 0.0754；按“差不多优先简单模型”规则，最终冻结更简单的 scalar gate 版本 C2，full-six Mean Skill_MSE = 0.0783，non-abrupt = 0.0835，co-seismic = 0.0680。

阶段进展：明确了单模型路线里真正有效的是 conservative residual gating，而不是更重的空间 gate。

不足与止损原因：query token 有限度贡献，但不足以成为最核心论文点；另外只有 24 个 tile-horizon 单元中的 2 个仍为负值，说明 abrupt 场景并未根治。

V2 follow-ups：M2 / M2+Skill / M3 / M4

阶段目标：继续验证 baseline-bank、skill-aware penalty、long-history 和 descriptor-gated 结构是否能超越 M1。

参考模型/已有方法：M1 作为已通过 GO 的主线参考。

主要结果：四个 follow-up 都没有超过 M1；最佳 M3 仍为负 skill，M2/M2+Skill 几乎重合，M4 最差。

阶段进展：排除了“再加复杂部件就会更强”的直觉。

不足与止损原因：说明单模型的主要瓶颈不在简单增大结构表达力，而在强 persistence 场景下的 error control。

V3：结构改进 quick sanity check

阶段目标：测试 bounded residual、 periodic branch、 轻量 SimVP-ACT proxy 等结构方向。

参考模型/已有方法：阈值以 M1 三 tile 0.0446 为参考，要求明显超过 0.0746。

主要结果：V3-A/B/C quick 的 Mean Skill_MSE 仅 0.0114、 -0.0037、 0.0135，全部未过线。

阶段进展：快速止损，避免在明显弱于 M1 的分支上浪费 full-six 预算。

不足与止损原因：这些结构即便复杂度可接受，也没有形成足够性能增益。

V4：状态空间 / 神经算子路线

阶段目标：探索比 M1 更有方法创新感的多尺度状态空间架构。

参考模型/已有方法：以 M1 为 accuracy-efficiency 参考线，重点看 V4-A/B/C。

主要结果：V4-A quick 仅 0.0427；强行继续后，V4-C 真实精度一度达到 0.0911 ± 0.0152，但训练时间约 55.8s，远超 M1 的 5× 门槛。

阶段进展：首次证明“更复杂状态空间架构在精度上可能成立”。

不足与止损原因：原始 V4-C 的失败不是精度，而是复杂度；因此后续转入 efficiency rescue。

V4-C efficiency rescue 与 C3_opt

阶段目标：把 V4-C 从 accuracy-credible but compute-no-go 压缩为 practical model。

参考模型/已有方法：候选包括工程优化版、 two-scale、 shared-SSM、 depthwise temporal 等；对照 M1。

主要结果：C3 原始 quick 为 0.0779、 33.24s；运行时优化后 C3_opt 训练时间降到约 14.1s，搜索集 quick 0.0836，但 six-tile 只到 0.0796，较 M1 只高 0.0012，且仅 2/6 tile 优于 M1。

阶段进展：复杂度问题被解决了一半，证明 high-res temporal mixer 可以做快。

不足与止损原因：真正失败点从“算得慢”变成“full-six 泛化不足”；因此 V4 路线保留为 near-pass evidence，而非最终主模型。

五、V5-V8+：从专家选择到专家聚合的路线转移

V5：风险感知专家选择器

阶段目标：让模型在 `{Persistence, Linear-Seasonal, M1, C3_opt}` 之间学习何时选哪个 expert。

参考模型/已有方法：oracle、rule-based、soft selector、hard selector、risk-aware selector；M1 为单模型基线。

主要结果：oracle 空间很强（patch oracle gain vs M1 = +0.1667）；soft quick 到 0.1210；但 best risk-aware 3-seed 只有 0.0964，增益 vs M1 仅 +0.0181，低于替代门槛。

阶段进展：证明专家互补空间真实存在，选择器方向值得继续。

不足与止损原因：学习型 selector 未能稳定把 oracle 空间兑现到 six-tile 主门槛，E44N23 成为主要 failure mode。

V6：风险校准锚定软选择器

阶段目标：用 anchor + risk calibration 改善 V5 的不稳定权重更新。

参考模型/已有方法：V5 selector 家族与 oracle。

主要结果：V6-A/B/C 均明显失败；best V6 3-seed Mean Skill_MSE = -0.1041，stress ratio = 1.2110。

阶段进展：这一步没有带来正结果，但迫使项目做了完整的 sanity checks。

不足与止损原因：后续 sanity check 证明不是 cache 对齐 bug，而是 selector 本身在 full-six 上学到了错误偏置，权重塌向 linear-seasonal，且 oracle expert label 也难以准确预测。

V6 sanity checks

阶段目标：确认 V6 失败是否源于实现错误、cache 对齐错误或 oracle teacher 不可学。

参考模型/已有方法：检查 expert cache、target 对齐、alpha 与 expert weights、oracle-teacher labels。

主要结果：cache 对齐完全通过；alpha 并未保护 stress tile；expert 权重大幅塌到 linear-seasonal；patch-level oracle teacher accuracy 仅约 0.3552。

阶段进展：明确排除了“实现 bug 杀死 V6”的解释。

不足与止损原因：只能得出 selector 输入特征不足以稳定识别最优 expert，或者这种 global anchored selector 形式不适合 full-six。

V7：CRCF / COEA 在线聚合

阶段目标：从 selector 切换到 tile×horizon 在线专家聚合，尝试在不直接选单一 expert 的前提下融合强基线。

参考模型/已有方法：equal-weight、 static validation-weighted、 COEA、 CRCF-COEA、 M1、 Persistence、 Linear-Seasonal。

主要结果：经 causal replay audit 修正后，COEA audited full-six Mean Skill_MSE = 0.1322，CRCF = 0.1273，均显著高于 M1 = 0.0783，且 stress 安全。

阶段进展：第一次在 six-tile 上系统性地超过单模型路线，并保持良好 stress 控制。

不足与止损原因：最小消融暴露出更简单的 static validation-weighted averaging 甚至更强，因此 online update 不能直接写成必要贡献。

StaticVal_EA / VCEA 为什么更强

阶段目标：解释为什么 static validation weighting 会强于 COEA，并决定主文是否切到 VCEA。

参考模型/已有方法：对照 VCEA、 COEA、 CRCF-COEA、 M1，以及 zero-delay oracle、 frozen-after-warm、 eta/floor 敏感性与 expert removal。

主要结果：VCEA 最优配置 `StaticVal_inverse_temp4p0_sh0p1_floor0p0` 达到 Mean Skill_MSE = 0.1776，显著高于 COEA 0.1322；validation-to-test rank stability 的 mean Spearman = 0.7778，top2 retention = 0.9167。

阶段进展：把项目主线从'在线聚合更先进'调整为'强基线感知的静态验证聚合更稳'。

不足与止损原因：VCEA 的 stress ratio = 1.0463，高于 COEA，因此精度最强并不等于部署最稳，后续必须做 safety hardening。

V8：STR-Mamba / KINO / CoMEx / RCDN 新架构深度研究

阶段目标：在聚合主线之外，再次测试更强的新型序列或算子架构能否单独或作为 VCEA 增量模块带来收益。

参考模型/已有方法：M1、 VCEA，以及 candidate-alone / VCEA+candidate 双门槛。

主要结果：KINO 全面失败；CoMEx_B 或 CoMEx_dualhead_nodiv 有一定正信号，但达不到对 VCEA 的加成门槛；STR-Mamba 先在 Windows 阶段受环境阻塞，后经 WSL2 Ubuntu + CUDA + 真实 `mamba_ssm` rerun，真实 STR_Mamba quick 也只有 candidate Mean Skill_MSE = 0.0554，未过线。

阶段进展：澄清了环境问题与真实性能问题：Mamba 最终是跑通了，但性能仍不够。

不足与止损原因：V8+ 说明再引入更前沿的新架构，并不能自动解决本任务的强 baseline 和 regime shift 问题，因此主线应回到 VCEA。

六、 DSCF、确认实验、基础设施重构与 hardening

DSCF 探索

阶段目标：尝试将任务改写为更显式的 deformation-state consistency 方向。

参考模型/已有方法：DSCF-0 / LF / MS / RC / Full，以及 `VCEA+DSCF` 的 validation-calibrated expert 扩展。

主要结果：没有任何 DSCF 版本通过 quick gate；最佳单体仍为负 gain，最佳 `VCEA+DSCF` 增益约 +0.0082，低于阈值。

阶段进展：把 DSCF 保留为 diagnostic 方向，而不是正式主线。

不足与说明：DSCF 未形成足够的增益、stress 与 tile coverage 证据，因此明确 no-go。

冻结后确认实验：external locked + 64/128/512 sensitivity

阶段目标：在不再重新搜索模型的前提下，检查冻结主线的外部泛化与分辨率稳健性。

参考模型/已有方法：VCEA 为主线；M1/C3_opt/Persistence/Linear-Seasonal 为对照。

主要结果：external VCEA Mean Skill_MSE = 0.3172，gain vs M1 = +0.1568，stress ratio = 0.9741；M1 在 64/128/512 上依次退化为 0.0473 / 0.0278 / 0.0150。

阶段进展：确认了主线 aggregation 在 external locked set 上仍有效，同时证明 64×64 主任务设置并不是因分辨率太低才限制性能。

不足与说明：高分辨率 exact aggregation 一度需要 proxy/transfer 近似，因此 128/512 只应作为 sensitivity/robustness，不应改写主任务。

family-level resolution extension

阶段目标：补测 M0、C3_opt、COEA_exact、VCEA_exact 在 64/128/512 上的 family-level 分辨率表现。

参考模型/已有方法：除 M1 外，再看更复杂单模型与 aggregation family 是否被分辨率压制。

主要结果：VCEA_exact 随分辨率上升从 0.1504 -> 0.1727 -> 0.1889，COEA_exact 也从 0.1289 -> 0.1341 -> 0.1446；M1 则持续下降。

阶段进展：得出一个关键结论：分辨率并没有限制 aggregation family 的发挥，相反更高分辨率给了它们更多可利用信息。

不足与说明：这个结论主要成立于 aggregation family，不能外推到所有复杂单模型；C3_opt@512 仍有 stress 风险，且部分 high-res 结果依赖 transfer/validation cache reuse。

infra_v2 基础设施重构

阶段目标：把分散实验产物统一到可追溯、可审计的 schema / manifest / registry / migrated result layer 中。

参考模型/已有方法：不是模型比较，而是结果治理；主线冻结为 64×64 mainline、128/512 sensitivity、external locked eval。

主要结果：迁移 589 行结果，显式区分 exact/proxy/transfer，补齐 product/tile/resolution manifest、split registry、expert cache registry 与 paper-ready summary tables。

阶段进展：让后期论文写作、claim-to-result mapping 与 reproducibility 审计有了统一底层结构。

不足与说明：它不改变模型结论，但改变了结果的可用性与可防御性，因此属于基础设施成果而不是性能成果。

TGRS_VCEA_hardening 包

阶段目标：围绕冻结后的 VCEA 主线补齐机制解释、安全部署、分辨率叙事与 reproducibility 证据。

参考模型/已有方法：VTSA、SS-VCEA、resolution-aware、reproducibility 四条子包。

主要结果：VTSA 证实 validation-to-test 排名稳定性（Spearman 0.7778）；SS-VCEA 选中 `SS-VCEA-COEA_q97p5`，main-six Mean Skill_MSE = 0.1648，stress ratio = 0.9917；external 上该变体为 conservative deployment variant，Mean Skill_MSE = 0.3015。

阶段进展：把‘为什么 VCEA 有效’、‘如何降低 stress 风险’、‘claim 对应哪些证据’三件事补齐到投稿可用水平。

不足与说明：SS-VCEA 的风险定义使用 equal-normalized risk，是文档未给出 lambda 时的显式工程假设；external 上它是 safety trade-off，而不是全面优于 VCEA。

七、全项目主要成果、最终论文结论与仍保留的不足

7.1 最终可写入论文主文的主要成果

- 建立了一个 leakage-safe 的 EGMS 2019-2023 Ortho U 区域地表形变 nowcasting 基准：六个 main-six tile + 四个 external locked tile，统一 split、normalization、valid-mask、manifest 与 audit。
- 完成了从 E1-E8 到 V8+ 的系统模型搜索，覆盖辅助特征、架构消融、多步长预测、跨站点迁移、有限本地校准、分辨率敏感性、物理一致性、门控残差、状态空间、专家选择、在线聚合、静态聚合与安全 hardening。
- 证明了在本任务上，单一复杂神经结构并不自动优于强 persistence baseline；单模型路线的最稳结果是 M1/C2，full-six Mean Skill_MSE 约 0.0783。
- 发现更强的主线来自强基线感知专家聚合。VCEA 在 six-tile 上达到 Mean Skill_MSE = 0.1776，显著高于 COEA = 0.1322 和 M1 = 0.0783。
- 通过 VTSA 证明了 validation-to-test expert ranking stability 是 static aggregation 有效的重要机制基础，而 COEA 受 delayed feedback 与 update drift 拖累。
- 构建了 SS-VCEA 保守部署变体：`SS-VCEA-COEA_q97p5` 在 main-six 上仅以小幅 skill 损失换取更低 stress（0.9917），适合写作中的 safety trade-off 版本。
- 用 external locked evaluation 证明聚合主线具备跨 tile 泛化：VCEA external Mean Skill_MSE = 0.3172，gain vs M1 = +0.1568，stress ratio = 0.9741。
- 通过 family-level resolution extension 证明：高分辨率并未限制 aggregation family 的发挥；受限的是早期单模型，尤其 M1 这类 coarse nowcasting 模型。
- 完成 infra_v2 重构与 hardening reproducibility map，使 exact/proxy/transfer、external locked、resolution sensitivity 和 paper claim source 都可追溯。

7.2 建议论文主线表述

- 主方法主线应写为 Strong-Baseline-Aware Expert Aggregation，而不是继续把单一 ACT-Former 变体作为唯一中心。
- 精度主结果建议以 VCEA 为主；部署与安全讨论建议并列报告 SS-VCEA。
- COEA 可作为 online aggregation 对照和机制支撑；M1 保留为最强单模型 baseline。
- V3、V4、V5、V6、V8、DSCF 不应被删掉，而应作为系统搜索证据：说明研究并非只调一个模型，而是在多条路线充分试错后收敛到 aggregation family。

7.3 仍需在论文中保留的限制与假设

- 所有正式结果统一使用 EGMS 2019-2023 Ortho U，而非旧稿中的 2018-2022；原因是数据可得性与本地处理链成熟度限制。
- E4/E6 的 leave-one-tile-out 在当前回合是 exploratory 单源 proxy，而不是严格多源联合训练。
- 部分高分辨率补测包含 proxy / transfer inference / 128 validation cache reuse，因此 128/512 只能写成 sensitivity，而不是主任务结果。
- SS-VCEA 的风险函数采用 equal-normalized risk，是在文档未给出精确 lambda 时的显式工程假设。
- VCEA 是当前最强精度主线，但并非在所有 stress 口径下都绝对优于 safety wrapper；因此 external 上应把 SS-VCEA 写成 conservative deployment variant，而不是全面更优。

7.4 当前推荐的最终模型层级

模型	定位	Mean Skill_MSE	Stress ratio	写作建议
VCEA	main-six 精度主线	0.1776	1.0463	最高总体 skill，适合作为主结果模型
SS-VCEA-COEA_q97p5	保守部署变体	0.1648	0.9917	main-six 安全性更强，external 上作为 conservative deployment variant
COEA	online aggregation 对照	0.1322	0.9960	机制上有意义，但整体不如 VCEA
M1 / C2	最强单模型 baseline	0.0783	1.0023	证明 aggregation 优势的核心对照

附录：关键综合报告与总目录

- E1-E8 总报告：outputs/tgrs_2019_2023/TGRS_E1_E8_实验记录_2019_2023.md
- 必须补实验：outputs/tgrs_2019_2023/supplements/TGRS_必须补小实验_实验记录.md
- M1 full-six 与消融：outputs/tgrs_2019_2023/act_v2/m1_suite/act_v2_m1_suite_detailed_report.md
- V7 causal audit 与 finalization：outputs/tgrs_2019_2023/act_v7/finalization/
- StaticVal_EA 研究：outputs/tgrs_2019_2023/staticval_ea_study/
- confirmation：outputs/tgrs_2019_2023/confirmation/
- infra_v2：outputs/tgrs_2019_2023/infrastructure_v2/
- hardening package：outputs/tgrs_2019_2023/hardening_package/